Лабораторная работа № 1 по курсу дискретного анализа: сортировка за линейное время

Выполнил студент группы М8О-208Б-21 МАИ *Королев Илья*.

Условие

Кратко описывается задача:

1. Требуется разработать программу, осуществляющую ввод пар «ключ-значение», их упорядочивание по возрастанию ключа указанным алгоритмом сортировки за линейное время и вывод отсортированной последовательности.

   Тип ключа: почтовые индексы.

   Тип значения: строки переменной длины (до 2048 символов).

2. Вариант задания 2-2. Сортировка подсчётом.

Метод решения

Решение реализовано согласно варианту, сортировкой подсчётом. Сначала создается динамический массив counts, в котором будут храниться счетчики вхождений каждого ключа. Затем происходит подсчет количества вхождений каждого ключа в исходном массиве и запись значений в массив counts. После этого в массиве counts находятся позиции, на которые должны быть помещены элементы в отсортированном массиве. Далее выделяется динамический массив sorted `arr`, в который будут записываться отсортированные значения. Затем элементы исходного массива записываются в отсортированный массив с учетом найденных позиций. Полученный отсортированный массив копируется обратно в исходный массив.

Описание программы

Все реализовано в одно файле. Рассмотрим функцию Main()

1. В начале функции выделяется динамическая память для массива `data_of_key_value`, в котором будут храниться все значения. Затем создается массив структур `KeyValuePair` размера 1e7. Структура хранит в себе ключ и индексы начала и конца значения в массиве `data_of_key_value`. Это сделано для тогг, чтобы потребление памяти.

2. Далее в цикле считываются пары значений (int, char), где int - ключ, а char - значение. Считанные значения записываются в массив `data_of_key_value`. Значение len хранит текущую длину массива `data_of_key_value`.

3. Далее создается структура `one_str` и заполняется значениями:

   - ключом, считанным из входных данных;

   - левой границей диапазона значений в массиве `data_of_key_value`;

   - правой границей диапазона значений в массиве `data_of_key_value`.

4. Затем заполненная структура `one_str` записывается в массив `arr` и инкрементируется `idx`.

5. После цикла while вызывается функция `CountingSort`, которая сортирует массив `arr`. Затем циклом for выводятся отсортированные значения из массива `arr`, полученные из массива `data_of_key_value`.

6. В конце освобождается выделенная динамическая память для массивов `arr` и `data_of_key_value`.

Дневник отладки

1. В начале разработки были общие проблемы, связанные с тем как это реализовывать. Падало на 5м тесте с WA. Думал что проблема была в том, что я не обрабатываю строки с ключами но без значений: "123123 ". Потом проинтерпретировал условие "непустая строчка понял, что скорее всего иметься ввиду, что может быть пуста строчка. То есть надо дополнительно обрабатывать пустые строчки. В этот момент я считывал с файла. Пытался разобраться как это сделать. Решил это проблему вот так.

```
bool isWhitespaceLine = true;
for (char* p = buf; *p != '\0'; ++p) {
    if (*p != ' ' && *p != '\t' && *p != '\n' && *p != '\r') {
        isWhitespaceLine = false;
        break;
    }
}

if (isWhitespaceLine) {
    numLines --;
    delete[] value;
    continue;
}
```

2. Была проблема с большими затратами памяти. Как я понимаю сейчас, это было связанно с тем, что я криво работал с файлами и буфером, который нужен был для считывания количества строк. While я не мог так как в тот момент работал

со статической памятью. Каждый раз выделял по char [2048] для строки и передавал в структуру. Алгоритм падал на ML. В этот момент я решил, что буду: 1 работать терминальным вводом; 2 думать над тем, как не хранить в структуре значения. 1 оказалось гораздо проще, чем с файлом. 2 решил хранить в структуре только индекс начала и конца значения в`data_of_key_value`. Вывод реализовал так (позорный, но на тот момент по другому не мог)):

```
for (int i = 0; i < idx; ++i) {
    int temp = arr[i].key;
    int digits = 0;
    do{
        temp /= 10;
        digits++;
    }while (temp != 0);
    int zerosToAdd = 6 - digits;
    for (int i = 0; i < zerosToAdd; i++) {
        std::cout << "0";
    }
    //
    //printf("%06d\t",arr[i].key);
    std::cout << arr[i].key << "\t";
    for (int j = arr[i].value.left; j < arr[i].value.right; ++j) {
        std::cout << data_of_key_value[j];
    }
    std::cout << "\n";
}
```

3. Все выше меня привело к тому, что я набрал около 1.09s и ошибку TL на 13м тесте. Потом исправил вывод на адекватный(я так думаю):

```
for (int i = 0; i < idx; ++i) {
    printf("%06d\t",arr[i].key);
    for (int j = arr[i].value.left; j < arr[i].value.right; ++j) {
        std::cout << data_of_key_value[j];
    }
    std::cout << "\n";
}
```

Почему-то это не ускорило. Тогда я решил переписать на си(поменять несколько строчек). Решил я так, потому что из с++ я так и не понял что могу взять. Все это есть в си. Успешно переписал. Время сократилось на 0,4 секунды. Тут та все и зашло.

Тест производительности

По оси x количество строк, по оси y время в миллисекундах. Видим что время линейно. Замерял с помощью time.h.

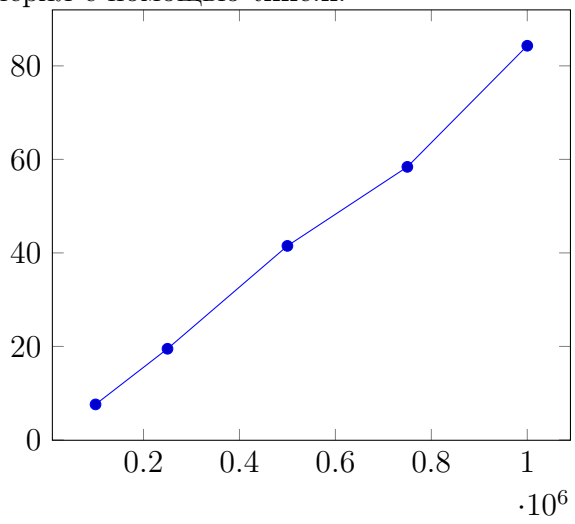

Недочёты

В целом, по ходу работы я расписал с какими трудностями я сталкнулся. Сейчас же все работает.

Выводы

Я понял , что сортировка подсчетом используется в задачах, где необходимо отсортировать последовательность из небольшого диапазона значений. Например, когда необходимо отсортировать массив целых чисел, в котором каждое число находится в диапазоне от 1 до 1000000.

Я думаю, что сортировка подсчетом применима например в таких практических задач:

- Определение наиболее часто встречающихся элементов в массиве.
- Сортировка списка студентов по их оценкам в порядке убывания или возрастания.
- Определение количества элементов в массиве, удовлетворяющих определенному условию.

Сложность по времени алгоритма сортировки подсчетом составляет O(n+k), где n - количество элементов в массиве, k - диапазон значений элементов. При этом, необходимо выделить дополнительную память для массива подсчета, размер которого также зависит от диапазона значений элементов.